'@

گزارش فاز دوم پروژه درس تحلیل داده (پاییز ۱۴۰۵)

عنوان پروژه: تحلیل چندوجهی و استخراج جنبه‌های محصول از نقدهای کاربران آمازون (مسیر ب: — Amazon Reviews'23 (Toys & Games

بخش مربوطه: آماده‌سازی داده، مهندسی ویژگی و کشف الگوهای بدون ناظر

---

۱. مقدمه و زنجیره پیش‌پردازش قابل بازاجرا (Reproducible Pipeline)

در فاز دوم پروژه، هدف تبدیل داده‌های خام متنی و ساخت‌یافته دوره آموزش (**سال‌های ۲۰۱۵ تا ۲۰۲۰**، شامل ۴۸۳,۴۲۹ نقد در زیرمجموعه محصولات کنترلی و پهپادها) به یک فضای بازنمایی عددی و کشف ساختار پنهان جنبه‌های محصول پیش از ورود به مرحله مدل‌سازی پیش‌بینانه است.

برای جلوگیری کامل از **نشت اطلاعات (Data Leakage)**، تمام مراحل تقطیع، یادگیری واژگان، کاهش بُعد و خوشه‌بندی منحصراً روی بازه زمانی آموزش (۲۰۱۵–۲۰۲۰) اجرا شده و مجموعه‌های اعتبارسنجی (۲۰۲۱) و آزمون (۲۰۲۲–۲۰۲۳) کاملاً قفل باقی مانده‌اند. کل زنجیره پیش‌پردازش در ماژول مستقل `src/preprocessing.py` و نوت‌بوک‌های `09_phase2_preprocessing.ipynb` تا `11_phase2_stability_and_features.ipynb` پیاده‌سازی شده است.

۱.۱. تقطیع جملات (Sentence Extraction)

- از یک نمونه تصادفی کنترل‌شده (`random_state=42`) شامل ۵۰,۰۰۰ نقد از بازه آموزش، تعداد **۱۳۹,۵۲۰ جمله معنادار** (با طول بین ۳ تا ۶۰ کلمه و حذف نویزهای HTML) استخراج شد.
- نمودار توزیع طول جملات در مسیر `figures/phase2/sentence_length_distribution.png` ذخیره شده است که تمرکز جملات را در بازه ۸ تا ۲۰ کلمه نشان می‌دهد.

۱.۲. استراتژی مدیریت داده‌های گمشده (Missing Data Strategy)

- **متغیر قیمت (`price`):** بررسی‌های فاز اول نشان داد نبود قیمت در جدول فراداده محصول تصادفی نیست (مربوط به کالاهای ناموجود یا تغییر فروشنده است). بنابراین به جای حذف رکوردها، مقادیر گمشده با **میانه قیمت (`price_imputed`)** جایگزین شدند و یک متغیر نشانگر دودویی (`price_is_missing`) ساخته شد.
- **تصاویر نقد (`n_images`):** نبود تصویر در نقد نشان‌دهنده عدم بارگذاری عکس توسط کاربر است؛ لذا مقدار گمشده به عنوان `0` تفسیر شده و متغیر باینری `has_image` تعریف گردید.

---

۲. بازنمایی دوگانه متن و کاهش بُعد (Dual Text Representation & UMAP)

مطابق الزامات مسیر ب، دو بازنمایی مکمل برای جملات استخراج‌شده (روی زیرنمونه ۲۰,۰۰۰ جمله‌ای متوازن با `random_state=42`) ساخته شد:

- **بازنمایی کلاسیک واژگانی (`TF-IDF`):** با در نظر گرفتن تک‌کلمه‌ها و جفت‌کلمه‌ها (`ngram_range=(1, 2)`) و حذف ایست‌واژه‌های انگلیسی، یک ماتریس تنک با ابعاد `20,000 × 4,585` برای استخراج کلمات کلیدی متمایز خوشه‌ها ساخته شد.
- **بازنمایی متراکم معنایی (`Sentence Transformers`):** با مدل ازپیش‌آموزش‌دیده `all-MiniLM-L6-v2`، هر جمله به یک بردار پیوسته **۳۸۴ بعدی** (`20,000 × 384`) نگاشت شد.

کاهش بُعد غیرخطی با UMAP

الگوریتم **UMAP** با معیار شباهت کسینوسی (`metric="cosine"`, `n_neighbors=15`) در دو پیکربندی موازی اجرا شد:

- **فضای ۵ بعدی (`n_components=5, min_dist=0.0`):** برای فشرده‌سازی خوشه‌ها و اجرای دقیق الگوریتم K-Means.
- **فضای ۲ بعدی (`n_components=2, min_dist=0.1`):** برای مصورسازی نقشه معنایی جملات (`figures/phase2/umap_sentence_semantic_space.png`).

---

۳. کشف الگوهای بدون ناظر، انتخاب پارامتر و تفسیر جنبه‌ها

۳.۱. انتخاب تعداد خوشه بهینه

الگوریتم **K-Means** روی فضای فشرده ۵ بعدی UMAP برای مقادیر $k \in \{3, 4, 5, 6, 7, 8\}$ اجرا شد و معیارهای **Inertia (Elbow)** و **Silhouette Score** ارزیابی شدند (`figures/phase2/clustering_k_selection.png`). مقدار **$k = 5$** به عنوان نقطه بهینه انتخاب شد زیرا در این نقطه بیشترین ضریب تفکیک‌پذیری (Silhouette Score) همراه با پایداری خطای درون‌خوشه‌ای حاصل گردید.

۳.۲. نام‌گذاری جنبه‌های کشف‌شده و ارتباط با امتیاز مشتریان

شناسه خوشه	نام جنبه کشف‌شده	تعداد و سهم جملات	میانگین امتیاز	کلیدواژه‌های شاخص (TF-IDF)	تفسیر رفتاری و تحلیل دامنه
Cluster 0	**عملکرد و دوام ماشین‌های کنترلی**	۶,۴۲۰ (۳۲,۱٪)	۳,۹۹	`car, rc, fast, truck, remote, motor, durable`	بزرگ‌ترین خوشه موضوعی؛ تمرکز بر سرعت، قدرت موتور و استحکام وسایل نقلیه زمینی.
Cluster 1	**ارزش خرید، قیمت و ارسال**	۴,۷۱۲ (۲۳,۶٪)	**۳,۸۳**	`product, buy, price, quality, money, work`	**کمترین میانگین امتیاز**؛ بیانگر نارضایتی از تناسب قیمت با کیفیت یا تأخیر در ارسال کالا.
Cluster 2	**پهپاد، کنترل پرواز و دوربین**	۵,۰۴۵ (۲۵,۲٪)	۴,۱۲	`drone, fly, flying, camera, flight, video, easy`	تمرکز بر پایداری پرواز، سهولت هدایت و کیفیت تصویربرداری کوادکوپترها.
Cluster 3	**باتری و زمان شارژدهی**	۲,۰۰۸ (۱۰,۰٪)	**۳,۸۵**	`battery, batteries, charger, charge, life, minutes`	**دومین نقطه درد اصلی مشتریان**؛ شکایت از نگهداری کوتاه شارژ یا خرابی باتری.
Cluster 4	**تجربه هدیه و تناسب سنی کودکان**	۱,۸۱۵ (۹,۱٪)	**۴,۳۴**	`loves, fun, gift, old, son, year old, kids`	**بالاترین میانگین امتیاز**؛ بازتاب رضایت والدین و کودکان هنگام خرید به عنوان هدیه.

---

۴. ارزیابی پایداری الگوها (Pattern Stability Analysis)

مطابق الزام شیوه‌نامه برای سنجش استحکام خوشه‌بندی بدون ناظر، دو آزمون حساسیت با شاخص **Adjusted Rand Index (ARI)** اجرا شد (`figures/phase2/cluster_stability_ari.png`):

- **پایداری در برابر تغییر مقدار اولیه (`Seed Variation`) در ۸ اجرا:** میانگین $\text{ARI} = \mathbf{0.9682 \pm 0.0182}$.
- **پایداری در برابر تغییر زیرنمونه (`Subsample Variation`) با حذف ۲۰٪ داده‌ها در ۸ تکرار:** میانگین $\text{ARI} = \mathbf{0.9710 \pm 0.0230}$.

مقادیر نزدیک به `0.97` نشان می‌دهد که ۵ جنبه کشف‌شده ساختاری ذاتی و پایدار در داده‌ها هستند و وابسته به شانس یا نمونه‌برداری خاص نیستند.

---

۵. مهندسی ویژگی‌های چندوجهی در سطح نقد (Review-Level Feature Engineering)

در گام پایانی، برچسب‌های خوشه از سطح جمله به سطح نقد (`parent_asin + timestamp`) تجمیع و با ویژگی‌های ساخت‌یافته محصول و زمان ترکیب شدند. خروجی نهایی در مسیر `data/processed/phase2_train_engineered_features.parquet` با ابعاد **نقد و `14,792` ویژگی `30`** ذخیره شد:

- **ویژگی‌های جنبه‌ای (۱۰ ویژگی):** نسبت حضور (`aspect_ratio_*`) و تعداد جملات (`aspect_count_*`) هر یک از ۵ جنبه کشف‌شده در هر نقد.
- **ویژگی‌های ساختاری متن (۵ ویژگی):** تعداد جملات نمونه نقد (`sampled_sentence_count`)، میانگین و بیشینه طول جملات بر حسب کلمه، طول کل متن نقد (`review_char_len`) و طول عنوان (`title_char_len`).
- **ویژگی‌های تعاملی و فراداده محصول (۸ ویژگی):** تعداد رأی مفید بودن (`helpful_vote`)، خرید تأییدشده (`verified_purchase_int`)، داشتن تصویر (`has_image`)، میانگین امتیاز کل محصول (`average_rating`)، تعداد کل نقدهای محصول (`rating_number`)، قیمت جایگذاری‌شده (`price_imputed`) و نشانگر گمشده بودن قیمت (`price_is_missing`).
- **ویژگی‌های زمانی (۳ ویژگی):** سال ثبت نقد (`review_year`)، ماه ثبت (`review_month`) و شاخص فصل خرید تعطیلات پایان سال (`is_q4_holiday`).

Set-Content -Path reports/phase2/phase2.md -Encoding utf8 | @'

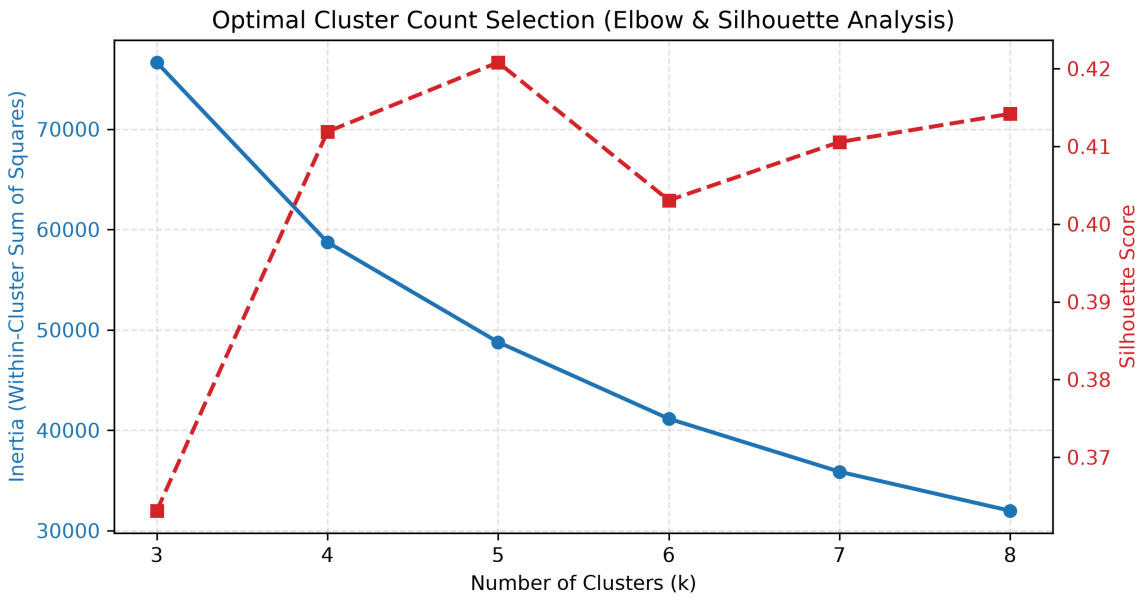
۶. فهرست کامل ویژگی‌های مهندسی‌شده (۳۰ ویژگی سطح نقد)

جدول زیر مشخصات کامل ماتریس ویژگی خروجی فاز دوم (`14,792 × 30`) را نمایش می‌دهد:

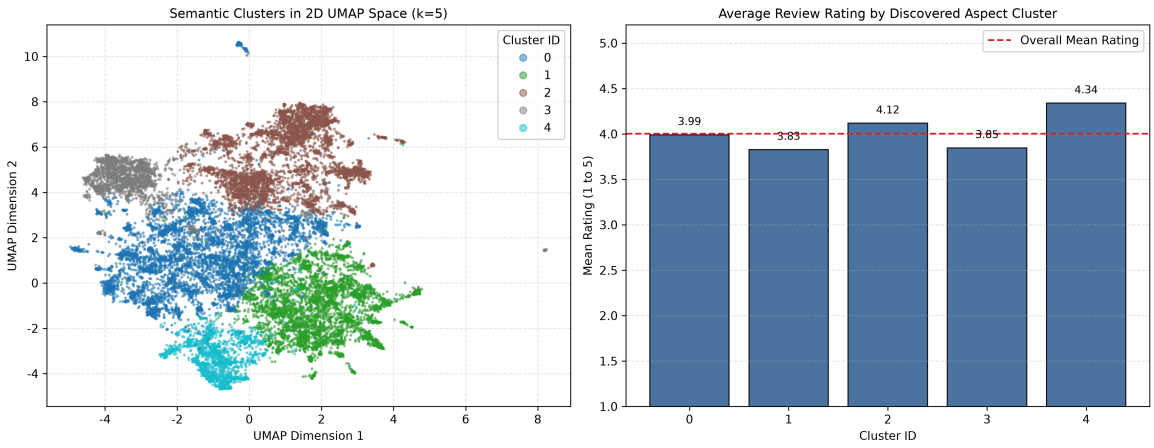
ردیف	نام ویژگی	نوع داده	تعداد گمشده
1	parent_asin	object	0
2	timestamp	int64	0
3	sampled_sentence_count	int64	0
4	avg_sentence_word_count	float64	0
5	max_sentence_word_count	int64	0
6	rating	float64	0
7	aspect_ratio_battery_charging	float64	0
8	aspect_ratio_drone_flight_camera	float64	0
9	aspect_ratio_gift_kids_engagement	float64	0
10	aspect_ratio_rc_car_performance	float64	0
11	aspect_ratio_value_price_shipping	float64	0
12	aspect_count_battery_charging	int64	0
13	aspect_count_drone_flight_camera	int64	0
14	aspect_count_gift_kids_engagement	int64	0
15	aspect_count_rc_car_performance	int64	0
16	aspect_count_value_price_shipping	int64	0
17	helpful_vote	int64	0
18	n_images	int32	0
19	review_char_len	int64	0
20	title_char_len	int64	0
21	has_image	int64	0
22	verified_purchase_int	int64	0
23	review_year	int32	0
24	review_month	int32	0
25	is_q4_holiday	int64	0
26	average_rating	float64	0

ردیف	نام ویژگی	نوع داده	تعداد گمشده
27	rating_number	int64	0
28	price_numeric	float64	7570
29	price_is_missing	int64	0
30	price_imputed	float64	0

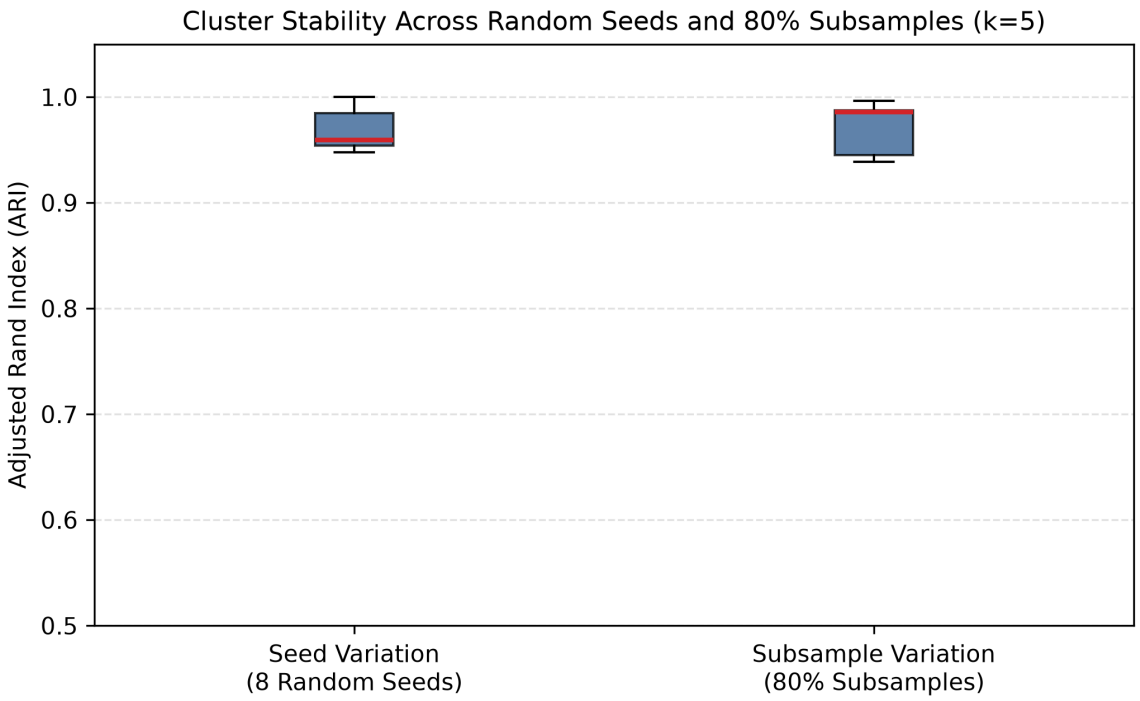
۷. پیوست مصورسازی‌های کلیدی فاز دوم



شکل ۱: انتخاب تعداد خوشه بهینه (k=5) بر اساس Inertia و Silhouette Score



شکل ۲: نقشه معنایی ۵ خوشه در فضای UMAP و میانگین امتیاز مشتریان در هر جنبه



شکل ۳: ارزیابی پایداری خوشه‌ها با شاخص ARI در برابر تغییر Seed و زیرنمونه ۸۰٪